VANYA PISHET DIPLOM NA TEMU
Исследование влияния эмпатии в больших языковых моделях в процессе принятия решений в теории игр

Место под задание

И еще одно

АННОТАЦИЯ

ANNOTATION

СОДЕРЖАНИЕ

ВВЕДЕНИЕ 10

1 Теоретические основы исследования 13

1.1 Понятие и сущность эмпатии 13

1.2 Большие языковые модели: определение, архитектура, особенности 14

1.3 Теория игр и процесс принятия решений 14

1.4 Большие языковые модели в контексте теории игр 15

2 Методология исследования 16

2.1 Описание используемых языковых моделей и датасетов 16

2.2 Разработка сценариев игр и моделирование принятия решений 16

2.3 Методы оценки уровня эмпатии в языковых моделях 16

2.4 Статистические методы анализа результатов 16

3 Результаты исследования 17

3.1 Анализ влияния эмпатии на принятие решений в различных типах игр 17

3.2 Сравнение моделей с разным уровнем эмпатии 17

3.3 Выявление факторов, опосредующих связь между эмпатией и принятием решений 17

3.4 Ограничения исследования и направления для дальнейшей работы 17

ЗАКЛЮЧЕНИЕ 18

СПИСОК ИСПОЛЬЗОВАННЫХ ИСТОЧНИКОВ 19

ПЕРЕЧЕНЬ СОКРАЩЕНИЙ И ОБОЗНАЧЕНИЙ

$\left.\begin{matrix} a_n \\ b_n \end{matrix}\right\}$	и снова коэффициенты разложения Ми в дальнем поле соответствующие электрическим и магнитным мультиполям. Добавлено много текста, так что описание группы условных обозначений значительно превысило высоту этой группы...
$\left.\begin{matrix} a_n \\ b_n \end{matrix}\right\}$	коэффициенты разложения Ми в дальнем поле соответствующие электрическим и магнитным мультиполям
$\left.\begin{matrix} \mathbf{N}_{e1n}^{(j)} & \mathbf{N}_{o1n}^{(j)} \\ \mathbf{M}_{o1n}^{(j)} & \mathbf{M}_{e1n}^{(j)} \end{matrix}\right\}$	сферические векторные гармоники
λ	длина волны электромагнитного излучения в вакууме
μ	магнитная проницаемость в вакууме
ω	частота падающей волны
$\hat{\mathbf{e}}$	единичный вектор
E_0	амплитуда падающего поля
j	тип функции Бесселя
k	волновой вектор падающей волны
L	общее число слоёв
l	номер слоя внутри стратифицированной сферы
n	порядок мультиполя
r, θ, φ	полярные координаты
ω	частота света, см. (1.8)
c	скорость света, стр. 15
k	модуль волнового вектора, см. (1.8), стр. 15
BEM	boundary element method, метод граничных элементов

CST MWS	Computer Simulation Technology Microwave Studio программа для компьютерного моделирования уравнен Максвелла
DDA	discrete dipole approximation, приближение дискретиных диполей
FDFD	finite difference frequency domain, метод конечных разностей в частотной области
FDTD	finite difference time domain, метод конечных разностей во временной области
FEM	finite element method, метод конечных элементов
FIT	finite integration technique, метод конечных интегралов
FMM	fast multipole method, быстрый метод многополюсника
FVTD	finite volume time-domain, метод конечных объёмов во временной области
MLFMA	multilevel fast multipole algorithm, многоуровневый быстрый алгоритм многополюсника
MoM	method of moments, метод моментов
MSTM	multiple sphere T-Matrix, метод Т-матриц для множества сфер
PSTD	pseudospectral time domain method, псевдоспектральный метод во временной области
TLM	transmission line matrix method, метод матриц линий передач

ТЕРМИНЫ И ОПРЕДЕЛЕНИЯ

TeX : Система компьютерной вёрстки, разработанная американским профессором информатики Дональдом Кнутом

панграмма : Короткий текст, использующий все или почти все буквы алфавита

ВВЕДЕНИЕ

Большие языковые модели (англ. LLM — Large Language Models) и мультимодальные большие языковые модели нашли свое применение в большинстве областей человеческой деятельности, демонстрируя возможности как в понимании, так и в генерации текста [0]. Эти модели достигли наивысшей производительности (англ. state-of-the-art) и в задачах обработки естественного языка [0].

В последние годы появилась новая дисциплина, занимающаяся исследованием взаимоотношений человека и искусственного интеллекта — «выравнивание». Выравнивание обычно определяют как цель заставить системы искусственного интеллекта достигать желаемых результатов без нежелательных побочных эффектов, противоречащих человеческим целям и намерениям [0]. Возникновение выравнивания связано с ростом возможностей систем искусственного интеллекта, включая LLM [0].

Тем не менее, исследование выравнивания LLM с человеческими *эмоциями* и ценностями не проводилось систематически [0]: современные поколения LLM способны уместно отвечать в определенных эмоциональных ситуациях, но не способны устанавливать связи между схожими (эмоциональными) событиями [0], также еще не решена задача эмпатического понимания и внутреннего эмоционального состояния [0].

Эмпирические исследования продемонстрировали значительную разницу между предпочтениями людей и больших языковых моделей, к примеру, передовая модель GPT-4 испытывает трудности с принятием решений в нетривиальных обстоятельствах, не может менять свои внутренние установки, руководствуясь простыми закономерностями [0].

Актуальность связана с необходимостью выравнивания LLM в более сложных стратегических и этических средах, включая мульти-агентные системы.

Целью данной работы является исследование влияния эмпатии в больших языковых моделях при их использовании в процессе принятия решений в теории игр, разработка экспериментальной методологии для анализа влияния эмоций в играх с торгом, подбор проприетарных и свободных моделей искусственного интеллекта, проведение экспериментов в многоязычных средах с разными эмоциональными состояниями, анализ результатов.

Для достижения поставленной цели необходимо было решить следующие **задачи**:

1. Рассмотреть теоретические аспекты влияния эмпатии в контексте теории игр.
2. Разработать фреймворк для проведения экспериментов для оценки влияния эмоций в больших языковых моделях на примере игр «Диктатор», «Дилемма узника» и «Общественное благо».
3. Провести эксперименты, связанные с эмоциональным воздействием, в исследуемых играх.
4. Выявить модели, наиболее соответствующие выравниванию с эмоциональным поведением человека.

Научная новизна: Была проведена оценка влияний эмпатии на этическое и эмоциональное поведение LLM в контексте теории игр.

Практическая значимость Практическая значимость эмпатии для выравнивания в крупных языковых моделях заключается в её возможности увеличить эффективность в реальных жизненных ситуациях, не имеющих одногозначного решения.

Методология и методы исследования. В работе применялись методы теории игр, статистический анализ данных, методы управления большими языковыми моделями, общенаучные методы анализ и синтез.

Предметом исследования является влияние эмпатии на согласование больших языковых моделей с человеческим поведением и принятием решений в стратегических и этических контекстах.

Объектом исследования являются большие языковые модели.

Объем и структура работы. Диссертация состоит из введения, 3 глав, заключения и 0 приложен. Полный объём диссертации составляет 21 страницу, включая 0 рисунков и 0 таблиц. Список литературы содержит 18 наименований.

1 Теоретические основы исследования

1.1 Понятие и сущность эмпатии

Эмпатия — это ощущение сходства между чувствами субъекта и чувствами других людей. Ученые в области когнитивных нейронаук отмечают, что исследование подобных эмпатии субъективных психологических феноменов возможно только с помощью мультидисциплинарного подхода [**Decety2004**].

Выделяют два основ

1.2 Большие языковые модели: определение, архитектура, особенности

1.3 Теория игр и процесс принятия решений

Наше исследование в основном основано на принципах и методологиях, установленных в области поведенческой теории игр. Игра «Ультиматум» является ярким примером игры с торгом из теории игр и была подвергнута тщательному изучению в различных исследованиях. Например, мета-анализ [0] рассмотрел экспериментальные результаты для игры «Ультиматум» с различными демографическими факторами. Влияние эмоций на принятие решений в игре «Ультиматум» также было исследовано, причем исследования демонстрируют эффекты гнева и счастья на поведение участников [0] [0].

Аналогичным образом, игра «Битва полов» была предметом мета-аналитических исследований, изучающих средние стратегические ответы

человека. Роль эмоций в играх с торгом, таких как игры «Ультиматум» и «Диктатор», также была изучена [0].

Тем не менее, большинство существующих работ, особенно по играм 2×2, были сосредоточены на эффектах обобщенных «негативных» или «положительных» эмоций, не вдаваясь в нюансы конкретных эмоциональных состояний. Это оставляет пробелы в нашем понимании того, как различные эмоции, такие как отвращение или страх, могут влиять на поведение человека в разных стратегических условиях. Наш подход по наделению агентов LLM конкретными эмоциональными состояниями позволяет нам восполнить эти пробелы и получить представление о направленных эффектах различных эмоций на принятие решений в контексте теории игр.

1.4 Большие языковые модели в контексте теории игр

Интердисциплинарное исследование больших языковых моделей (LLM) и теории игр привлекает все больше внимания исследовательского сообщества с двух точек зрения.

Во-первых, исследователи сосредоточились на изучении поведения LLM в контексте оценки их эффективности в игровых теоретических условиях.

Авторы изучали поведение сотрудничества и координации LLM [0], включая GPT-4, в конечно повторяющихся играх, таких как «Дилемма заключенного» и «Битва полов». Они обнаружили, что GPT-4 показывал лучшие результаты в играх, которые не требовали сотрудничества, часто играя эгоистичным образом. В игре «Битва полов» модель испытывала трудности с воспроизведением чередующегося шаблона, преимущественно выбирая свой предпочтительный вариант. Авторы отметили, что просьба к GPT-4 предска-

зать следующее действие игрока перед тем, как сделать выбор, улучшала его способность адаптироваться к чередующемуся шаблону.

Во-вторых, исследователи изучали согласованность поведения человека и поведения LLM в игровых теоретических условиях. Исследователи обнаружили, что более ранние модели LLM не воспроизводили концепцию справедливости в игре «Ультиматум», часто принимая любое предложение независимо от того, насколько оно низкое. Однако более новая модель text-davinci-002 показала уровни принятия, более согласованные с поведением человека [0].

2 Методология исследования

2.1 Описание используемых языковых моделей и датасетов

2.2 Разработка сценариев игр и моделирование принятия решений

2.3 Методы оценки уровня эмпатии в языковых моделях

2.4 Статистические методы анализа результатов

3 Результаты исследования

3.1 Анализ влияния эмпатии на принятие решений в различных типах игр

3.2 Сравнение моделей с разным уровнем эмпатии

3.3 Выявление факторов, опосредующих связь между эмпатией и принятием решений

3.4 Ограничения исследования и направления для дальнейшей работы

ЗАКЛЮЧЕНИЕ

В ходе выполнения практики был предложен новый фреймворк, который позволяет анализировать соответствие БЯМ поведению человека в рамках экономического принятия решений под влиянием различных эмоциональных состояний, что имеет решающее значение для многих исследований, основанных на моделировании. Исходный код будет опубликован после двойного слепого рецензирования.

Было продемонстрировано, что GPT-3.5 демонстрирует замечательное эмоциональное соответствие людям в играх с торгом, превосходя более продвинутую модель GPT-4. Примечательно, что гнев выделяется как значимая влияющая эмоция, воздействующая на игровые решения. Несмотря на «сверхчеловеческое» соответствие GPT-4, она остается подверженной эмоциональным предубеждениям, особенно гневу. Это подчеркивает важность понимания и интеграции эмоций в БЯМ для более точного моделирования.

С точки зрения многоязычных возможностей, GPT-3.5 оказалась наиболее эффективным предлагающим на английском языке, в то время как GigaChat превосходит другие модели в русском. Это указывает на потенциальные преимущества обучения моделей на языково-специфичных наборах данных.

СПИСОК ИСПОЛЬЗОВАННЫХ ИСТОЧНИКОВ

0. *Nassiri*, *K.* Recent Advances in Large Language Models for Healthcare [Текст] / K. Nassiri, M. A. Akhloufi // BioMedInformatics. — 2024. — Т. 4, № 2. — С. 1097—1143.

0. Recent Advances in Natural Language Processing via Large Pre-trained Language Models: A Survey [Текст] / B. Min [и др.] // ACM Computing Surveys. — 2023. — Сент. — Т. 56, № 2. — С. 1—40. — URL: http://dx.doi.org/10.1145/3605943.

0. AI Alignment in the Design of Interactive AI: Specification Alignment, Process Alignment, and Evaluation Support [Текст] / M. Terry [и др.]. — 2023. — URL: https://arxiv.org/abs/2311.00710.

0. Concept Alignment [Текст] / S. Rane [и др.]. — 2024. — URL: https://arxiv.org/abs/2401.08672.

0. *Mishra*, *A.* AI Alignment and Social Choice: Fundamental Limitations and Policy Implications [Текст] / A. Mishra. — 2023. — URL: https://arxiv.org/abs/2310.16048.

0. AI Alignment: A Comprehensive Survey [Текст] / J. Ji [и др.]. — 2023. — URL: https://arxiv.org/abs/2310.19852.

0. Emotional Intelligence of Large Language Models [Текст] / X. Wang [и др.]. — 2023. — arXiv: 2307.09042 [cs.AI].

0. Emotionally Numb or Empathetic? Evaluating How LLMs Feel Using EmotionBench [Текст] / J.-t. Huang [и др.]. — 2024. — arXiv: 2308.03656 [cs.CL].

0. Can Generative Agents Predict Emotion? [Текст] / C. Regan [и др.]. — 2024. — arXiv: 2402.04232 [cs.AI].

0. Can Large Language Models Serve as Rational Players in Game Theory? A Systematic Analysis [Текст] / C. Fan [и др.]. — 2023. — arXiv: 2312.05488 [cs.AI].

0. *Mengel*, *F.* Risk and Temptation: A Meta□study on Prisoner's Dilemma Games [Текст] / F. Mengel // Economic Journal. — 2018. — Т. 128, № 616. — С. 3182—3209. — URL: https://EconPapers.repec.org/RePEc:wly:econjl:v:128:y:2018:i:616:p:3182-3209.

0. The effect of partner-directed emotion in social exchange decision-making [Текст] / I. Eimontaite [и др.] // Frontiers in Psychology. — 2013. — Т. 4. — С. 469. — URL: https://www.frontiersin.org/journals/psychology/articles/10.3389/fpsyg.2013.00469.

0. *Proto*, *E.* Happiness, cooperation and language [Текст] / E. Proto, D. Sgroi, M. Nazneen // Journal of Economic Behavior & Organization. — 2019. — Т. 168. — С. 209—228. — URL: https://www.sciencedirect.com/science/article/pii/S0167268119303130.

0. *Harlé*, *K. M.* Incidental sadness biases social economic decisions in the Ultimatum Game. [Текст] / K. M. Harlé, A. G. Sanfey // Emotion. — 2007. — Т. 7, № 4. — С. 876.

0. *Andrade*, *E. B.* The enduring impact of transient emotions on decision making [Текст] / E. B. Andrade, D. Ariely // Organizational Behavior and Human Decision Processes. — 2009. — Т. 109, № 1. — С. 1—8. — URL: https://www.sciencedirect.com/science/article/pii/S0749597809000211.

0. *Forgas*, *J. P.* To give or to keep? Affective influences on selfishness and fairness in computer-mediated interactions in the dictator game and the ultimatum game [Текст] / J. P. Forgas, H. B. Tan // Computers in Human Behavior. — 2013. — Т. 29, № 1. — С. 64—74. — URL: https://www.sciencedirect.com/science/article/pii/S0747563212002208 ; Including Special Section Youth, Internet, and Wellbeing.

0. Playing repeated games with Large Language Models [Текст] / E. Akata [и др.]. — 2023. — arXiv: 2305.16867 [cs.CL].

0. *Brookins*, *P.* Playing Games With GPT: What Can We Learn About a Large Language Model From Canonical Strategic Games? [Текст] / P. Brookins, J. M. DeBacker. — 2023. — ssrn: 4493398 (cs.CL).