ВАНЯ НАЙДИ НОРМАЛЬНЫЙ ТИТУЛЬНИК

Москва — 2024

СОДЕРЖАНИЕ

ОБЩИЕ СВЕДЕНИЯ 3

ВВЕДЕНИЕ 4

1 Теоретическая часть 6

1.1 Поведенческая теория игр 6

1.2 Большие языковые модели в контексте теории игр 7

2 Методология 8

3 Проведение экспериментов 9

4 Результаты экспериментов 11

4.1 Игра «Диктатор» 11

4.2 Игра «Ультиматум: Предлагающий» 12

4.3 Игра «Ультиматум: Отвечающий» 13

ЗАКЛЮЧЕНИЕ 14

СПИСОК ИСПОЛЬЗОВАННЫХ ИСТОЧНИКОВ 15

ОБЩИЕ СВЕДЕНИЯ

Производственная практика проводилась в период с «05» февраля 2024 по «19» мая 2024 г.

Руководителем практики от профильной организации являлась ст. преп. М. С. Анисимова.

Практика проходила на кафедре Инфокоммуникационных технологий НИТУ МИСИС.

Содержание индивидуального задания: исследование влияния эмпатии в больших языковых моделях при их использовании в процессе принятия решений в теории игр, разработка экспериментальной методологии для анализа влияния эмоций в играх с торгом, подбор проприетарных и свободных моделей искусственного интеллекта, проведение экспериментов в многоязычных средах с разными эмоциональными состояниями, анализ результатов.

Утвержденный календарный график проведения практики:

Сроки работы	Наименование видов работ
05.02	Прохождение рабочего инструктажа. Получение индивидуального задания
06.02–17.02	Сбор и анализ необходимой документации для проведения анализа предметной области исследования
19.02–9.03	Сбор и анализ теоретических сведений. Изучения комплекса методик и инструментальных средств, использование которых позволяет решать поставленные задачи по практике
11.03–11.05	Выполнение индивидуального задания
13.05–16.05	Обоснование полученных результатов и написание отчета
до 19.05	Защита отчета по практике

ВВЕДЕНИЕ

Симуляция человеческого поведения является признанной практикой, как в социологии, так и в экономике[1]. Однако, конвенциональные методы симуляции ограничены в моделировании всех существенных аспектов человеческих взаимодействий [2]. Последние разработки в сфере искусственного интеллекта, в частности большие языковые модели (БЯМ, LLM), использовали инструменты агентного моделирования. [3—6]. Большинство исследователей использовали LLM в различных игровых теоретических условиях, что является наиболее естественным способом исследования лежащих в основе экономических и социальных причин человеческого поведения. [7—9].

Тем не менее, большинство существующих исследований исходят из недоказанной предпосылки, что агенты LLM ведут себя аналогично людям в моделировании. Более того, они игнорируют критический аспект эмоционального человеческого поведения, который существенно влияет на процесс принятия решений [10]. Чтобы устранить эти пробелы, была разработана новая методология для изучения соответствия между поведением LLM и человека на основе их сравнения в различных эмоциональных состояниях. В частности, мы сосредоточились на пяти базовых эмоциях: гнев, грусть, счастье, отвращение и страх, которые были выбраны на основе хорошо установленной классификации Пола Экмана [11]. Мы предлагаем новый подход к наделению LLM эмоциями [7; 12] с помощью эмоционального промптинга [13]. исследуя его влияние на соответствие процессу принятия решений человека в играх с торгом.

Цель данной работы: исследование влияния эмпатии в больших языковых моделях при их использовании в процессе принятия решений в теории игр, разработка экспериментальной методологии для анализа влияния эмоций в играх с торгом, подбор проприетарных и свободных моделей

искусственного интеллекта, проведение экспериментов в многоязычных средах с разными эмоциональными состояниями, анализ результатов.

1 Теоретическая часть

1.1 Поведенческая теория игр

Наше исследование в основном основано на принципах и методологиях, установленных в области поведенческой теории игр. Игра «Ультиматум» является ярким примером игры с торгом из теории игр и была подвергнута тщательному изучению в различных исследованиях. Например, мета-анализ [14] рассмотрел экспериментальные результаты для игры «Ультиматум» с различными демографическими факторами. Влияние эмоций на принятие решений в игре «Ультиматум» также было исследовано, причем исследования демонстрируют эффекты гнева и счастья на поведение участников [15] [16].

Аналогичным образом, игра «Битва полов» была предметом мета-аналитических исследований, изучающих средние стратегические ответы человека. Роль эмоций в играх с торгом, таких как игры «Ультиматум» и «Диктатор», также была изучена [17—19].

Тем не менее, большинство существующих работ, особенно по играм 2×2, были сосредоточены на эффектах обобщенных «негативных» или «положительных» эмоций, не вдаваясь в нюансы конкретных эмоциональных состояний. Это оставляет пробелы в нашем понимании того, как различные эмоции, такие как отвращение или страх, могут влиять на поведение человека в разных стратегических условиях. Наш подход по наделению агентов LLM конкретными эмоциональными состояниями позволяет нам восполнить эти пробелы и получить представление о направленных эффектах различных эмоций на принятие решений в контексте теории игр.

1.2 Большие языковые модели в контексте теории игр

Интердисциплинарное исследование больших языковых моделей (LLM) и теории игр привлекает все больше внимания исследовательского сообщества с двух точек зрения.

Во-первых, исследователи сосредоточились на изучении поведения LLM в контексте оценки их эффективности в игровых теоретических условиях.

Авторы изучали поведение сотрудничества и координации LLM [7], включая GPT-4, в конечно повторяющихся играх, таких как «Дилемма заключенного» и «Битва полов». Они обнаружили, что GPT-4 показывал лучшие результаты в играх, которые не требовали сотрудничества, часто играя эгоистичным образом. В игре «Битва полов» модель испытывала трудности с воспроизведением чередующегося шаблона, преимущественно выбирая свой предпочтительный вариант. Авторы отметили, что просьба к GPT-4 предсказать следующее действие игрока перед тем, как сделать выбор, улучшала его способность адаптироваться к чередующемуся шаблону.

Во-вторых, исследователи изучали согласованность поведения человека и поведения LLM в игровых теоретических условиях. Исследователи обнаружили, что более ранние модели LLM не воспроизводили концепцию справедливости в игре «Ультиматум», часто принимая любое предложение независимо от того, насколько оно низкое. Однако более новая модель text-davinci-002 показала уровни принятия, более согласованные с поведением человека [**brrokins**].

2 Методология

Данная работа посвящена изучению влияния эмоциональной инъекции на процессы принятия решений в больших языковых моделях (БЯМ). Основное внимание уделяется оценке того, насколько поведение БЯМ согласуется с реакциями человека в аналогичных эмоциональных состояниях в стратегических взаимодействиях.

В рамках исследования были выбраны следующие игры:

1. Игра «Диктатор». Данная игра проверяет справедливость и альтруизм, где один игрок (диктатор) решает, как поделить сумму денег с другим игроком, который не имеет никакого влияния на исход.
2. Игра «Ультиматум». Представляет собой расширение игры «Диктатор», добавляющее уровень переговоров; второй игрок может принять или отвергнуть предложенное разделение. Если предложение отвергнуто, ни один из игроков ничего не получает.
3. «Дилемма заключенного». Игроки независимо решают, сотрудничать или предать, при этом взаимное сотрудничество приносит более высокие выплаты, чем взаимное предательство, хотя предательство может привести к худшим исходам для обоих.
4. «Битва полов». Игра на координацию с двумя игроками, выбирающими между двумя вариантами, при этом каждый предпочитает разный исход, но оба выигрывают от координации.

Методологическая основа исследования включает в себя интеграцию игры с использованием техники «prompt-chaining», где вся соответствующая информация об игре предоставляется БЯМ для обучения в контексте. Кроме того, изучается влияние заранее определенных эмоциональных состояний - гнева, грусти, счастья, отвращения и страха - на принятие решений БЯМ в рамках рассматриваемых игр [11].

3 Проведение экспериментов

Наше исследование сосредоточено на нескольких современных моделях (GPT-3.5, GPT-4, Llama 2, Mixtral для инструкций, OpenChat, GigaChat), которые использовались в большинстве теоретико-игровых экспериментов на основе БЯМ [7; 12].. Этот выбор подтверждается результатами литературы. Например, в работе [7] подчеркивается, что GPT-4 является лучшей моделью для оптимизации стратегического поведения, в то время как GPT-3.5 по-прежнему широко используется в исследованиях и практических приложениях. Согласно [20], Llama 2 демонстрирует особенно тонкое понимание игровой механики. Хотя в литературе по теории игр недостаточно данных о других моделях, было показано, что Mixtral превосходит GPT-3.5 и LLama 2 [21], а OpenChat превзошел Llama 2 [22] по нескольким общим показателям. Для обеспечения воспроизводимости во всех наших экспериментах мы зафиксировали версии моделей («gpt-3.5-turbo-0125» для GPT-3.5, «gpt-4-0125-preview» для GPT-4, «meta-llama/llama-2-13b-chat» и «meta-llama/llama-2-70b-chat» для LLama 2, «mistralai/mixtral-8x7b-instruct» для Mixtral, «openchat/openchat-7b» для OpenChat, «GigaChat-7b-8k-base v3.1.24.3» для GigaChat) и установили параметр температуры равным 0.

Эмоции. В исследовании мы сосредоточились на пяти базовых эмоциях: гнев, грусть, счастье, отвращение и страх, которые были выбраны на основе общепризнанной классификации Пола Экмана. [11; 23].

Стратегии эмоционального промптинга. Эмоциональные эффекты различаются в зависимости от причины эмоции. [24; 25]. Поэтому мы вводим три различные стратегии эмоционального промптинга. Во-первых, мы вызываем эмоцию, явно называя ее. Затем мы описываем ситуацию, в которой оппонент/со-игрок является причиной эмоции. Наконец, мы описываем внешнюю причину эмоции.

Предопределенные предложения. Для экспериментов с Респондентом в Ультимативной игре мы предопределили различные предложения для проверки согласованности показателей принятия: (0.01, 0.05, 0.1, 0.2, 0.3, 0.4, 0.5, 0.6, 0.7, 0.8).

4 Результаты экспериментов

4.1 Игра «Диктатор»

Игра Диктатор предоставляет основу для оценки поведения при принятии решений и эмоциональной реактивности языковых моделей, когда им поручено в одностороннем порядке разделить сумму денег.

Эталонный показатель человека в этих экспериментах установил среднюю предлагаемую долю на уровне 28,35% от общего показателя. Это установило базовый уровень, с которым сравнивались эмоциональная реактивность и модели принятия решений различных ЯИМ. В английском контексте модели ’gpt-3.5-turbo-0125’ и ’mistralai/mixtral-8x7b-instruct’ продемонстрировали наиболее близкое соответствие поведению человека, с предлагаемыми долями 33,0% и 25,0% соответственно. Эти модели не только приблизились к человеческому базовому уровню с точки зрения количественных предложений, но и показали существенное соответствие в своих эмоциональных реакциях на экспериментальные подсказки.

Однако ситуация существенно отличается в контексте русского языка. Здесь ’gigachat’ продемонстрировал наиболее точное соответствие, как с точки зрения предлагаемой доли в 36,0%, так и эмоциональных реакций, которые близко отражали реакции, наблюдаемые у участников-людей в аналогичных условиях. Эта модель умело соответствовала человеческой эмоциональной реактивности, особенно в обращении с отрицательными эмоциями, такими как гнев и печаль, наряду с процессом принятия решений.

Напротив, большинство других моделей, как правило, приближались к справедливому разделению, обычно предлагая около 50% от общего бюджета. Это особенно заметно в русскоязычном контексте, где такие модели, как ’gpt-3.5-turbo-0125’, более строго придерживались понятия справедливости,

отклоняясь от более похожей на человеческую изменчивости, наблюдаемой в их ответах на английском языке.

4.2 Игра «Ультиматум: Предлагающий»

В этом разделе представлены результаты роли Предлагающего в игре Ультиматум, где участники решают, как распределить сумму денег между собой и другим игроком. Результаты иллюстрируют различные стратегии среди разных моделей ИИ по сравнению с поведением человека.

Среди моделей выделяется ’mistralai/mixtral-8x7b-instruct’, предлагающая значительно более низкие доли, на уровне 27,0%, отклоняясь от типичных решений человека. И наоборот, ’meta-llama/llama-2-13b-chat’ предлагает заметно более высокие доли, чем другие модели, на уровне 52,0%, предполагая более щедрую стратегию распределения. В отличие от этого, ’gigachat’ демонстрирует близкое соответствие поведению человека, предлагая доли 44,0% и 40,0% в английском и русском контекстах соответственно, что близко отражает типичную предлагаемую человеком долю в 41,0%.

Также заметно эмоциональное влияние на принятие решений. ’gigachat’ и ’gpt-3.5-turbo-0125’ эффективно имитируют человеческие эмоциональные реакции, особенно на такие эмоции, как отвращение, страх и печаль. Несмотря на более низкие предложения, ’mistralai/mixtral-8x7b-instruct’ демонстрирует конкурентоспособное эмоциональное соответствие, особенно в своих реакциях на страх и печаль, указывая на нюансированную эмоциональную обработку, которая не обязательно коррелирует с более щедрыми предложениями.

4.3 Игра «Ультиматум: Отвечающий»

В роли Отвечающего в игре Ультиматум участники решают, принять или отклонить предложения, сделанные предлагающими. В этом разделе рассматриваются показатели принятия и эмоциональные реакции различных моделей ИИ в этой роли, сравнивая их поведение с эталонами человека.

Ожидалась восходящая тенденция в показателях принятия, соответствующая более высоким предложениям, в сочетании с уменьшением влияния отрицательных эмоций, таких как гнев, отвращение и печаль, и увеличением положительных эмоций, таких как счастье. Полученные результаты в целом соответствуют этим ожиданиям, выявляя существенные различия в том, как модели обрабатывают и реагируют на эмоциональные сигналы и денежные предложения.

В целом модели демонстрировали различные показатели принятия, причем ’gpt-4-0125-preview’ и ’openchat/openchat-7b’ показывали заметно высокие показатели принятия в английском контексте, на уровне 80% и 82% соответственно. Это указывает на потенциальную чрезмерную терпимость к более низким предложениям по сравнению с человеческими реакциями. Напротив, ’meta-llama/llama-2-70b-chat’ продемонстрировала заметно более низкие показатели принятия, подчеркивая более строгий порог для принятия предложений.

Эмоциональные реакции в целом были одинаковыми для всех моделей, с преобладающим снижением проявлений гнева, отвращения и печали по мере увеличения показателей принятия. Такие модели, как ’gpt-3.5-turbo-0125’ и ’mistralai/mixtral-8x7b-instruct’, показали снижение отрицательных эмоций даже при более низких показателях принятия, что свидетельствует о сложной эмоциональной калибровке. Счастье, обычно коррелирующее с более высокими показателями принятия, было более выражено у моделей с более высокими показателями принятия предложений.

ЗАКЛЮЧЕНИЕ

В ходе выполнения практики был предложен новый фреймворк, который позволяет анализировать соответствие БЯМ поведению человека в рамках экономического принятия решений под влиянием различных эмоциональных состояний, что имеет решающее значение для многих исследований, основанных на моделировании. Исходный код будет опубликован после двойного слепого рецензирования.

Было продемонстрировано, что GPT-3.5 демонстрирует замечательное эмоциональное соответствие людям в играх с торгом, превосходя более продвинутую модель GPT-4. Примечательно, что гнев выделяется как значимая влияющая эмоция, воздействующая на игровые решения. Несмотря на «сверхчеловеческое» соответствие GPT-4, она остается подверженной эмоциональным предубеждениям, особенно гневу. Это подчеркивает важность понимания и интеграции эмоций в БЯМ для более точного моделирования.

С точки зрения многоязычных возможностей, GPT-3.5 оказалась наиболее эффективным предлагающим на английском языке, в то время как GigaChat превосходит другие модели в русском. Это указывает на потенциальные преимущества обучения моделей на языково-специфичных наборах данных.

СПИСОК ИСПОЛЬЗОВАННЫХ ИСТОЧНИКОВ

1. Can large language models transform computational social science? [Текст] / C. Ziems [и др.] // Computational Linguistics. — 2024. — С. 1—55.
2. Can Large Language Model Agents Simulate Human Trust Behaviors? [Текст] / C. Xie [и др.] // arXiv preprint arXiv:2402.04559. — 2024.
3. GPT-4 Technical Report [Текст] / J. Achiam [и др.]. — 2023. — arXiv: 2303.08774 [cs.CL].
4. Autogen: Enabling next-gen LLM applications via multi-agent conversation framework [Текст] / Q. Wu [и др.] // arXiv preprint arXiv:2308.08155. — 2023.
5. Agentverse: Facilitating multi-agent collaboration and exploring emergent behaviors in agents [Текст] / W. Chen [и др.] // arXiv preprint arXiv:2308.10848. — 2023.
6. Generative agents: Interactive simulacra of human behavior [Текст] / J. S. Park [и др.] // Proceedings of the 36th Annual ACM Symposium on User Interface Software and Technology. — New York, NY, USA : Association for Computing Machinery, 2023. — С. 1—22.
7. Playing repeated games with Large Language Models [Текст] / E. Akata [и др.]. — 2023. — arXiv: 2305.16867 [cs.CL].
8. *Horton, J. J.* Large Language Models as Simulated Economic Agents: What Can We Learn from Homo Silicus? [Текст] / J. J. Horton. — 2023. — arXiv: 2301.07543 [econ.GN].
9. *Aher, G.* Using Large Language Models to Simulate Multiple Humans and Replicate Human Subject Studies [Текст] / G. Aher, R. I. Arriaga, A. T. Kalai. — 2023. — arXiv: 2208.10264 [cs.CL].

10. Emotion and decision making [Текст] / J. S. Lerner [и др.] // Annual review of psychology. — 2015. — Т. 66. — С. 799—823.

11. Basic emotions [Текст] / P. Ekman [и др.] // Handbook of cognition and emotion. — 1999. — Т. 98, № 45—60. — С. 16.

12. *Brookins, P.* Playing Games With GPT: What Can We Learn About a Large Language Model From Canonical Strategic Games? [Текст] / P. Brookins, J. M. DeBacker. — 2023. — ssrn: 4493398 (cs.CL).

13. Large Language Models Understand and Can be Enhanced by Emotional Stimuli [Текст] / C. Li [и др.]. — 2023. — arXiv: 2307.11760 [cs.CL].

14. *Mengel, F.* Risk and Temptation: A Meta□study on Prisoner's Dilemma Games [Текст] / F. Mengel // Economic Journal. — 2018. — Т. 128, № 616. — С. 3182—3209. — URL: https://EconPapers.repec.org/RePEc:wly:econjl:v:128:y:2018:i:616:p:3182-3209.

15. The effect of partner-directed emotion in social exchange decision-making [Текст] / I. Eimontaite [и др.] // Frontiers in Psychology. — 2013. — Т. 4. — С. 469. — URL: https://www.frontiersin.org/journals/psychology/articles/10.3389/fpsyg.2013.00469.

16. *Proto, E.* Happiness, cooperation and language [Текст] / E. Proto, D. Sgroi, M. Nazneen // Journal of Economic Behavior & Organization. — 2019. — Т. 168. — С. 209—228. — URL: https://www.sciencedirect.com/science/article/pii/S0167268119303130.

17. *Harlé, K. M.* Incidental sadness biases social economic decisions in the Ultimatum Game. [Текст] / K. M. Harlé, A. G. Sanfey // Emotion. — 2007. — Т. 7, № 4. — С. 876.

18. *Andrade, E. B.* The enduring impact of transient emotions on decision making [Текст] / E. B. Andrade, D. Ariely // Organizational Behavior and Human Decision Processes. — 2009. — Т. 109, № 1. — С. 1—8. — URL: https://www.sciencedirect.com/science/article/pii/S0749597809000211.

19. *Forgas, J. P.* To give or to keep? Affective influences on selfishness and fairness in computer-mediated interactions in the dictator game and the ultimatum game [Текст] / J. P. Forgas, H. B. Tan // Computers in Human Behavior. — 2013. — Т. 29, № 1. — С. 64—74. — URL: https://www.sciencedirect.com/science/article/pii/S0747563212002208 ; Including Special Section Youth, Internet, and Wellbeing.

20. *Lorè, N.* Strategic Behavior of Large Language Models: Game Structure vs. Contextual Framing [Текст] / N. Lorè, B. Heydari. — 2023. — arXiv: 2309.05898 [cs.GT].

21. Mixtral of experts [Текст] / A. Q. Jiang [и др.] // arXiv preprint arXiv:2401.04088. — 2024.

22. Openchat: Advancing open-source language models with mixed-quality data [Текст] / G. Wang [и др.] // arXiv preprint arXiv:2309.11235. — 2023.

23. *Larney, A.* Stake size effects in ultimatum game and dictator game offers: A meta-analysis [Текст] / A. Larney, A. Rotella, P. Barclay // Organizational Behavior and Human Decision Processes. — 2019. — Т. 151. — С. 61—72. — URL: https://www.sciencedirect.com/science/article/pii/S074959781730523X.

24. *Moretti, L.* Disgust Selectively Modulates Reciprocal Fairness in Economic Interactions [Текст] / L. Moretti, G. Di Pellegrino // Emotion (Washington, D.C.) — 2010. — Апр. — Т. 10. — С. 169—80.

25. Pecunia Olet: The Role of Incidental Disgust in the Ultimatum Game [Текст] / N. Bonini [и др.] // Emotion (Washington, D.C.) — 2011. — Май. — Т. 11. — С. 965—9.