VANYA PISHET DIPLOM NA TEMU
Исследование влияния эмпатии в больших языковых моделях в процессе принятия решений в теории игр

Место под задание

И еще одно

АННОТАЦИЯ

ANNOTATION

СОДЕРЖАНИЕ

ВВЕДЕНИЕ 10

1 Теоретические основы исследования 15

1.1 Понятие и сущность эмпатии 15

1.2 Большие языковые модели: определение, архитектура, особенности 15

1.3 Теория игр и процесс принятия решений 15

1.4 Большие языковые модели в контексте теории игр 16

2 Методология исследования 17

2.1 Описание используемых языковых моделей и датасетов 17

2.2 Разработка сценариев игр и моделирование принятия решений 17

2.3 Методы оценки уровня эмпатии в языковых моделях 17

2.4 Статистические методы анализа результатов 17

3 Результаты исследования 18

3.1 Анализ влияния эмпатии на принятие решений в различных типах игр 18

3.2 Сравнение моделей с разным уровнем эмпатии 18

3.3 Выявление факторов, опосредующих связь между эмпатией и принятием решений 18

3.4 Ограничения исследования и направления для дальнейшей работы 18

ЗАКЛЮЧЕНИЕ 19

СПИСОК ИСПОЛЬЗОВАННЫХ ИСТОЧНИКОВ 20

ПЕРЕЧЕНЬ СОКРАЩЕНИЙ И ОБОЗНАЧЕНИЙ

$\left.\begin{matrix} a_n \\ b_n \end{matrix}\right\}$	и снова коэффициенты разложения Ми в дальнем поле соответствующие электрическим и магнитным мультиполям. Добавлено много текста, так что описание группы условных обозначений значительно превысило высоту этой группы...
$\left.\begin{matrix} a_n \\ b_n \end{matrix}\right\}$	коэффициенты разложения Ми в дальнем поле соответствующие электрическим и магнитным мультиполям
$\left.\begin{matrix} \mathbf{N}_{e1n}^{(j)} & \mathbf{N}_{o1n}^{(j)} \\ \mathbf{M}_{o1n}^{(j)} & \mathbf{M}_{e1n}^{(j)} \end{matrix}\right\}$	сферические векторные гармоники
λ	длина волны электромагнитного излучения в вакууме
μ	магнитная проницаемость в вакууме
ω	частота падающей волны
$\hat{\mathbf{e}}$	единичный вектор
E_0	амплитуда падающего поля
j	тип функции Бесселя
k	волновой вектор падающей волны
L	общее число слоёв
l	номер слоя внутри стратифицированной сферы
n	порядок мультиполя
r, θ, φ	полярные координаты
ω	частота света, см. (1.8)
c	скорость света, стр. 15
k	модуль волнового вектора, см. (1.8), стр. 15
BEM	boundary element method, метод граничных элементов

CST MWS	Computer Simulation Technology Microwave Studio программа для компьютерного моделирования уравнен Максвелла
DDA	discrete dipole approximation, приближение дискретиных диполей
FDFD	finite difference frequency domain, метод конечных разностей в частотной области
FDTD	finite difference time domain, метод конечных разностей во временной области
FEM	finite element method, метод конечных элементов
FIT	finite integration technique, метод конечных интегралов
FMM	fast multipole method, быстрый метод многополюсника
FVTD	finite volume time-domain, метод конечных объёмов во временной области
MLFMA	multilevel fast multipole algorithm, многоуровневый быстрый алгоритм многополюсника
MoM	method of moments, метод моментов
MSTM	multiple sphere T-Matrix, метод Т-матриц для множества сфер
PSTD	pseudospectral time domain method, псевдоспектральный метод во временной области
TLM	transmission line matrix method, метод матриц линий передач

ТЕРМИНЫ И ОПРЕДЕЛЕНИЯ

TeX : Система компьютерной вёрстки, разработанная американским профессором информатики Дональдом Кнутом

панграмма : Короткий текст, использующий все или почти все буквы алфавита

ВВЕДЕНИЕ

Большие языковые модели (англ. LLM — Large Language Models) и мультимодальные большие языковые модели нашли свое применение в большинстве областей человеческой деятельности, демонстрируя примечательные возможности как в понимании, так и в генерации текста [1]. Эти модели достигли наивысшей производительности (англ. state-of-the-art) и в задачах обработки естественного языка [2].

В последние годы возникла новая дисциплина, занимающаяся исследованием взаимоотношений человека и искусственного интеллекта — «выравнивание». Выравнивание обычно определяют как цель заставить системы искусственного интеллекта достигать желаемых результатов без нежелательных побочных эффектов, противоречащих человеческим целям и намерениям. [3—5]. Возникновение выравнивания связано с ростом возможностей систем искусственного интеллекта, включая LLM [6].

Тем не менее, исследование выравнивания LLM с человеческими *эмоциями* и ценностями не проводилось систематически [7]: нынешние поколения LLM способны уместно отвечать в определенных эмоциональных ситуациях, но не способны устанавливать связи между схожими (эмоциональными) событиями [8], также еще не решена задача эмпатического понимания и внутреннего эмоционального состояния [9].

Недавние эмпирические исследования продемонстрировали значительную разницу между предпочтениями людей и больших языковых моделей, к примеру, передовая модель GPT-4 испытывает трудности с принятием решений в нетривиальных обстоятельствах, не может менять свои внутренние установки, руководствуясь простыми закономерностями [10].

Следовательно,

Обзор, введение в тему, обозначение места данной работы в мировых исследованиях и т. п., можно использовать ссылки на другие работы [11;

12] (если их нет, то в автореферате автоматически пропадёт раздел «Список литературы»). Внимание! Ссылки на другие работы в разделе общей характеристики работы можно использовать только при использовании `biblatex` (из-за технических ограничений `bibtex8`. Это связано с тем, что одна и та же характеристика используются и в тексте диссертации, и в автореферате. В последнем, согласно ГОСТ, должен присутствовать список работ автора по теме диссертации, а `bibtex8` не умеет выводить в одном файле два списка литературы). При использовании `biblatex` возможно использование исключительно в автореферате подстрочных ссылок для других работ командой `\autocite`, а также цитирование собственных работ командой `\cite`. Для этого в файле `common/setup.tex` необходимо присвоить положительное значение счётчику `\setcounter{usefootcite}{1}`.

Для генерации содержимого титульного листа автореферата, диссертации и презентации используются данные из файла `common/data.tex`. Если, например, вы меняете название диссертации, то оно автоматически появится в итоговых файлах после очередного запуска LaTeX. Согласно ГОСТ 7.0.11-2011 «5.1.1 Титульный лист является первой страницей диссертации, служит источником информации, необходимой для обработки и поиска документа». Наличие логотипа организации на титульном листе упрощает обработку и поиск, для этого разметите логотип вашей организации в папке images в формате PDF (лучше найти его в векторном варианте, чтобы он хорошо смотрелся при печати) под именем `logo.pdf`. Настроить размер изображения с логотипом можно в соответствующих местах файлов `title.tex` отдельно для диссертации и автореферата. Если вам логотип не нужен, то просто удалите файл с логотипом.

Этот абзац появляется только в диссертации. Через проверку условия `\ifsynopsis`, задаваемого в основном файле документа (`dissertation.tex` для диссертации), можно сделать новую команду, обеспечивающую появление цитаты в диссертации, но не в автореферате.

Целью данной работы является …

Для достижения поставленной цели необходимо было решить следующие **задачи**:

1. Исследовать, разработать, вычислить и т. д. и т. п.
2. Исследовать, разработать, вычислить и т. д. и т. п.
3. Исследовать, разработать, вычислить и т. д. и т. п.
4. Исследовать, разработать, вычислить и т. д. и т. п.

Научная новизна:

1. Впервые …
2. Впервые …
3. Было выполнено оригинальное исследование …

Практическая значимость …

Методология и методы исследования. …

Основные положения, выносимые на защиту:

1. Первое положение
2. Второе положение
3. Третье положение
4. Четвертое положение

В папке Documents можно ознакомиться с решением совета из Томского ГУ (в файле `Def_positions.pdf`), где обоснованно даются рекомендации по формулировкам защищаемых положений.

Достоверность полученных результатов обеспечивается … Результаты находятся в соответствии с результатами, полученными другими авторами.

Апробация работы. Основные результаты работы докладывались на: перечисление основных конференций, симпозиумов и т. п.

Личный вклад. Автор принимал активное участие …

Публикации. Основные результаты по теме диссертации изложены в 8 печатных изданиях, 2 из которых изданы в журналах, рекомендованных ВАК, 3 — в периодических научных журналах, индексируемых Web of Science и Scopus, 4 — в тезисах докладов. Зарегистрированы 1 патент и 1 программа для ЭВМ.

При использовании пакета `biblatex` будут подсчитаны все работы, добавленные в файл `biblio/author.bib`. Для правильного подсчёта работ в различных системах цитирования требуется использовать поля:

– `authorvak` если публикация индексирована ВАК,
– `authorscopus` если публикация индексирована Scopus,
– `authorwos` если публикация индексирована Web of Science,
– `authorconf` для докладов конференций,
– `authorpatent` для патентов,
– `authorprogram` для зарегистрированных программ для ЭВМ,
– `authorother` для других публикаций.

Для подсчёта используются счётчики:

– `citeauthorvak` для работ, индексируемых ВАК,
– `citeauthorscopus` для работ, индексируемых Scopus,
– `citeauthorwos` для работ, индексируемых Web of Science,
– `citeauthorvakscopuswos` для работ, индексируемых одной из трёх баз,
– `citeauthorscopuswos` для работ, индексируемых Scopus или Web of Science,
– `citeauthorconf` для докладов на конференциях,
– `citeauthorother` для остальных работ,
– `citeauthorpatent` для патентов,
– `citeauthorprogram` для зарегистрированных программ для ЭВМ,
– `citeauthor` для суммарного количества работ.

Для добавления в список публикаций автора работ, которые не были процитированы в автореферате, требуется их перечислить с использованием команды `\nocite` в `Synopsis/content.tex`.

Объем и структура работы. Диссертация состоит из введения, 3 глав, заключения и 0 приложен. Полный объём диссертации составляет 22 стра-

ницы, включая 0 рисунков и 0 таблиц. Список литературы содержит 20 наименований.

1 Теоретические основы исследования

1.1 Понятие и сущность эмпатии

1.2 Большие языковые модели: определение, архитектура, особенности

1.3 Теория игр и процесс принятия решений

Наше исследование в основном основано на принципах и методологиях, установленных в области поведенческой теории игр. Игра «Ультиматум» является ярким примером игры с торгом из теории игр и была подвергнута тщательному изучению в различных исследованиях. Например, мета-анализ [13] рассмотрел экспериментальные результаты для игры «Ультиматум» с различными демографическими факторами. Влияние эмоций на принятие решений в игре «Ультиматум» также было исследовано, причем исследования демонстрируют эффекты гнева и счастья на поведение участников [14] [15].

Аналогичным образом, игра «Битва полов» была предметом мета-аналитических исследований, изучающих средние стратегические ответы человека. Роль эмоций в играх с торгом, таких как игры «Ультиматум» и «Диктатор», также была изучена [16—18].

Тем не менее, большинство существующих работ, особенно по играм 2×2, были сосредоточены на эффектах обобщенных «негативных» или «положительных» эмоций, не вдаваясь в нюансы конкретных эмоциональных состояний. Это оставляет пробелы в нашем понимании того, как различные эмоции, такие как отвращение или страх, могут влиять на поведение человека в разных стратегических условиях. Наш подход по наделению агентов LLM конкретными эмоциональными состояниями позволяет нам восполнить

эти пробелы и получить представление о направленных эффектах различных эмоций на принятие решений в контексте теории игр.

1.4 Большие языковые модели в контексте теории игр

Интердисциплинарное исследование больших языковых моделей (LLM) и теории игр привлекает все больше внимания исследовательского сообщества с двух точек зрения.

Во-первых, исследователи сосредоточились на изучении поведения LLM в контексте оценки их эффективности в игровых теоретических условиях.

Авторы изучали поведение сотрудничества и координации LLM [19], включая GPT-4, в конечно повторяющихся играх, таких как «Дилемма заключенного» и «Битва полов». Они обнаружили, что GPT-4 показывал лучшие результаты в играх, которые не требовали сотрудничества, часто играя эгоистичным образом. В игре «Битва полов» модель испытывала трудности с воспроизведением чередующегося шаблона, преимущественно выбирая свой предпочтительный вариант. Авторы отметили, что просьба к GPT-4 предсказать следующее действие игрока перед тем, как сделать выбор, улучшала его способность адаптироваться к чередующемуся шаблону.

Во-вторых, исследователи изучали согласованность поведения человека и поведения LLM в игровых теоретических условиях. Исследователи обнаружили, что более ранние модели LLM не воспроизводили концепцию справедливости в игре «Ультиматум», часто принимая любое предложение независимо от того, насколько оно низкое. Однако более новая модель text-davinci-002 показала уровни принятия, более согласованные с поведением человека [20].

2 Методология исследования

2.1 Описание используемых языковых моделей и датасетов

2.2 Разработка сценариев игр и моделирование принятия решений

2.3 Методы оценки уровня эмпатии в языковых моделях

2.4 Статистические методы анализа результатов

3 Результаты исследования

3.1 Анализ влияния эмпатии на принятие решений в различных типах игр

3.2 Сравнение моделей с разным уровнем эмпатии

3.3 Выявление факторов, опосредующих связь между эмпатией и принятием решений

3.4 Ограничения исследования и направления для дальнейшей работы

ЗАКЛЮЧЕНИЕ

В ходе выполнения практики был предложен новый фреймворк, который позволяет анализировать соответствие БЯМ поведению человека в рамках экономического принятия решений под влиянием различных эмоциональных состояний, что имеет решающее значение для многих исследований, основанных на моделировании. Исходный код будет опубликован после двойного слепого рецензирования.

Было продемонстрировано, что GPT-3.5 демонстрирует замечательное эмоциональное соответствие людям в играх с торгом, превосходя более продвинутую модель GPT-4. Примечательно, что гнев выделяется как значимая влияющая эмоция, воздействующая на игровые решения. Несмотря на «сверхчеловеческое» соответствие GPT-4, она остается подверженной эмоциональным предубеждениям, особенно гневу. Это подчеркивает важность понимания и интеграции эмоций в БЯМ для более точного моделирования.

С точки зрения многоязычных возможностей, GPT-3.5 оказалась наиболее эффективным предлагающим на английском языке, в то время как GigaChat превосходит другие модели в русском. Это указывает на потенциальные преимущества обучения моделей на языково-специфичных наборах данных.

СПИСОК ИСПОЛЬЗОВАННЫХ ИСТОЧНИКОВ

1. *Nassiri*, *K.* Recent Advances in Large Language Models for Healthcare [Текст] / K. Nassiri, M. A. Akhloufi // BioMedInformatics. — 2024. — Т. 4, № 2. — С. 1097—1143.
2. Recent Advances in Natural Language Processing via Large Pre-trained Language Models: A Survey [Текст] / B. Min [и др.] // ACM Computing Surveys. — 2023. — Сент. — Т. 56, № 2. — С. 1—40. — URL: http://dx.doi.org/10.1145/3605943.
3. AI Alignment in the Design of Interactive AI: Specification Alignment, Process Alignment, and Evaluation Support [Текст] / M. Terry [и др.]. — 2023. — URL: https://arxiv.org/abs/2311.00710.
4. Concept Alignment [Текст] / S. Rane [и др.]. — 2024. — URL: https://arxiv.org/abs/2401.08672.
5. *Mishra*, *A.* AI Alignment and Social Choice: Fundamental Limitations and Policy Implications [Текст] / A. Mishra. — 2023. — URL: https://arxiv.org/abs/2310.16048.
6. AI Alignment: A Comprehensive Survey [Текст] / J. Ji [и др.]. — 2023. — URL: https://arxiv.org/abs/2310.19852.
7. Emotional Intelligence of Large Language Models [Текст] / X. Wang [и др.]. — 2023. — arXiv: 2307.09042 [cs.AI].
8. Emotionally Numb or Empathetic? Evaluating How LLMs Feel Using EmotionBench [Текст] / J.-t. Huang [и др.]. — 2024. — arXiv: 2308.03656 [cs.CL].
9. Can Generative Agents Predict Emotion? [Текст] / C. Regan [и др.]. — 2024. — arXiv: 2402.04232 [cs.AI].

10. Can Large Language Models Serve as Rational Players in Game Theory? A Systematic Analysis [Текст] / C. Fan [и др.]. — 2023. — arXiv: 2312.05488 [cs.AI].

11. Wafer bonding for microsystems technologies [Текст] / U. Gösele [и др.] // Sensors and Actuators A: Physical. — 1999. — Т. 74, № 1—3. — С. 161—168.

12. *Лермонтов*, *М. Ю.* Собрание сочинений: в 4 т. [Текст] / М. Ю. Лермонтов. — М. : Терра-Кн. клуб, 2009. — 4 т.

13. *Mengel*, *F.* Risk and Temptation: A Meta□study on Prisoner's Dilemma Games [Текст] / F. Mengel // Economic Journal. — 2018. — Т. 128, № 616. — С. 3182—3209. — URL: https://EconPapers.repec.org/RePEc:wly:econjl:v:128:y:2018:i:616:p:3182-3209.

14. The effect of partner-directed emotion in social exchange decision-making [Текст] / I. Eimontaite [и др.] // Frontiers in Psychology. — 2013. — Т. 4. — С. 469. — URL: https://www.frontiersin.org/journals/psychology/articles/10.3389/fpsyg.2013.00469.

15. *Proto*, *E.* Happiness, cooperation and language [Текст] / E. Proto, D. Sgroi, M. Nazneen // Journal of Economic Behavior & Organization. — 2019. — Т. 168. — С. 209—228. — URL: https://www.sciencedirect.com/science/article/pii/S0167268119303130.

16. *Harlé*, *K. M.* Incidental sadness biases social economic decisions in the Ultimatum Game. [Текст] / K. M. Harlé, A. G. Sanfey // Emotion. — 2007. — Т. 7, № 4. — С. 876.

17. *Andrade*, *E. B.* The enduring impact of transient emotions on decision making [Текст] / E. B. Andrade, D. Ariely // Organizational Behavior and Human Decision Processes. — 2009. — Т. 109, № 1. — С. 1—8. — URL: https://www.sciencedirect.com/science/article/pii/S0749597809000211.

18. *Forgas*, *J. P.* To give or to keep? Affective influences on selfishness and fairness in computer-mediated interactions in the dictator game and the ultimatum game [Текст] / J. P. Forgas, H. B. Tan // Computers in Human Behavior. — 2013. — Т. 29, № 1. — С. 64—74. — URL: https://www.sciencedirect.com/science/article/pii/S0747563212002208 ; Including Special Section Youth, Internet, and Wellbeing.

19. Playing repeated games with Large Language Models [Текст] / E. Akata [и др.]. — 2023. — arXiv: 2305.16867 [cs.CL].

20. *Brookins*, *P.* Playing Games With GPT: What Can We Learn About a Large Language Model From Canonical Strategic Games? [Текст] / P. Brookins, J. M. DeBacker. — 2023. — ssrn: 4493398 (cs.CL).